

# ベイズ推論概論

フワッと全体のイメージを持つベイズ

# 目次

---

- ベイズ推測とは

# **What's Bayes inference?**

みんな大好き渡辺ベイズでは...


真の確率分布で $q(x)$ はおおよそ $p^*(x)$ くらいだろう

と推測することとベイズ推測を定義している。

「ベイズ統計の理論と方法」 渡辺澄夫 コロナ社(2012) P 5 参照



真の確率分布？  $P^*(\mathbf{x})$ ?

# ベイズ推測の考え方




真の確率分布 $q(x)$

生成



サンプル


推測



- ・ データを生成しているルール
- ・ 確定しているが未知(観測はできない)
- ・ 一般にめちゃくちゃ複雑

予測するルールのことを予測分布と言う

以後、 予測分布は $p^*(x)$ と書く



観測



分析者

対象を生成してる  
ルールは大体  
 $p^*(x)$ だろうと推  
測する


生成されたサンプル（データ）から  
事象を支配するルールを推測する

# 定量的に扱う (真の確率分布・サンプル)

- $n, N$ : 自然数
- $N$ 次元実ユークリッド空間  $\mathbb{R}^N$

$n$  個の点の集合  $x_1, x_2, \dots, x_n$  について考える

$$x^n = (x_1, x_2, \dots, x_n) \in \mathbb{R}^N \times \mathbb{R}^N \times \dots \times \mathbb{R}^N$$




サンプル  $x_1, x_2, \dots, x_n$  が、  
真の確率分布  $q(x)$  に独立に従う  
確率変数の実現値であるとする

i.i.dの仮定

$x^n$  を  $(\mathbb{R}^N)^n$  上の分布

$$q(x^n) = \prod_{i=1}^n q(x_i) = q(x_1)q(x_2)\cdots q(x_n)$$



を持つ確率変数

$$X^n = (X_1, X_2, \dots, X_n)$$

の実現値として考える。

サンプルを確率変数の実現値



# 定量的に扱う（予測分布）

$p^*(x)$ を構成する

- ・ 確率モデル：  $p(x|w)$

パラメータ  $w \in W \subset \mathbb{R}^d$  が与えられたときの

$x \in \mathbb{R}^N$  の上の条件付き確率分布

- ・ 事前分布：  $\phi(w)$

$w \in W$  上の確率分布

$\beta$  : 逆温度と呼ばれるハイパーパラメータ

- ・ パラメータの事後分布

$$p(w|X^n) = \frac{1}{Z_n(\beta)} \phi(w) \prod_{i=1}^n p(X_i|w)^\beta$$

- ・ 分配関数（規格化定数）

$$Z_n(\beta) = \int_W \phi(w) \prod_{i=1}^n p(X_i|w)^\beta dw$$

統計力学同様、この分配関数を使って色々なことがわかる。

予測分布  $p^*(x)$  はこのパラメータの事後分布を使って定義する


# 定量的に扱う（予測分布）




分析者

対象を生成してる  
ルールは大体  
 $p^*(x)$ だろうと推  
測する


大体こんな感じ～



期待値～



平均値～



$$p^*(x) = \mathbb{E}_w[p(x|w)] \\ = \int p(x|w)p(w|X^n)dw$$

予測分布 := 事後分布によって確率モデルを平均したもの

では、「真の分布 $q(x)$ は大体 $p^*(x)$ くらいだろう。」と予測したとする



次に行うのは予測の評価だろう。

しかし、真の分布、データを支配しているルールを知りたいけど知りようがない。

むしろ、知れるなら統計的に予測なんてしなくていい。

どうやって、評価したらいいのか、なんの道具を使えばいいのか。。


真の確率分布 $q(x)$



大体 $p^*(x)$ これやな



この違いを測りたい  
汎化損失と呼ぶ



これは直接測れない。。

真の確率分布含んでるし。。

この違いを推定するものがある。

それが**WAIC**

とかAIC

- WAIC

$$W_n = T_n + \frac{\beta V_n}{n}$$

- $T_n$ : 経験損失


$$T_n = -\frac{1}{n} \sum_{i=1}^n \log \mathbb{E}_w[p(X_i | w)]$$

- $V_n$ : 汎関数分散

$$V_n = \sum_{i=1}^n \{ \mathbb{E}_w[(\log p(X_i | w))^2] - \mathbb{E}_w[\log p(X_i | w)]^2 \}$$

$W_n$ の期待値が

理論的に汎化損失の期待値と  
漸近的に一致する




小さければ、

汎化損失の期待値も小さい

いい感じの予測





## ・ベイズ統計の理論と方法

詳しくはこの本を読むか著者のHPへ

書籍名クリックでAmazonへHPクリックでHPへ飛びます

douyatte?



A partial view of Doraemon's face on the left side of the image. It shows his white face, blue collar, and a red and orange triangular pattern on his cheek. A speech bubble tail points from his mouth towards the text box.

統計モデリングへ

pythonでベイズ推論を行うには大きく二つのパッケージがある。

- pystan

stanファイルに確率モデルを記述してベイズ推論を行う

ドキュメント：<https://pystan.readthedocs.io/en/latest/>

- PyMC3

pythonのみで完結する。速度はまあ、

ドキュメント：<https://docs.pymc.io/>

どちらもMCMCを行なってベイズ推論を行う。


# 定量的に扱う（予測分布）




分析者

対象を生成してる  
ルールは大体  
 $p^*(x)$ だろうと推  
測する


大体こんな感じ～



期待値～



平均値～



$$p^*(x) = \mathbb{E}_w[p(x|w)] \\ = \int p(x|w)p(w|X^n)dw$$


再掲

予測分布 := 事後分布によって確率モデルを平均したもの

## 定量的に扱う（予測分布）

---

$$\begin{aligned} p^*(x) &= \mathbb{E}_w[p(x|w)] \\ &= \int p(x|w)p(w|X^n)dw \\ &= \int p(x|w) \frac{\phi(w) \prod_{i=1}^n p(X_i|w)^\beta}{\int_W \phi(w) \prod_{i=1}^n p(X_i|w)^\beta dw} dw \end{aligned}$$



学習したパラメータの分だけ多重積分になっている


この部分が複雑で計算が難しいので、**MCMC**を使う

# MCMCとは

これには条件があるが本スライドでは割愛


乱数を使って発生させたサンプルが  
パラメータの事後分布からのサンプルとみなせるアルゴリズム

posterior




パラメータの事後分布は複雑！

MCMCサンプル



生成プログラムは[こちら](#)

MCMCサンプルを得れば、得たサンプルと確率モデルを使って予測分布が作れる



こういうの